Curs bàsic d'Anàlisi de dades amb Stata

1

Sessió 2

- Estadística descriptiva
 - Estadístics descriptius
 - Mitjanes, Medianes, Intervals de Confiança, Percentils
 - Gràfics descriptius variables cuantitatives
 - Taules de contingència
 - Taules epidemiológiques (incidència prevalença)
 - Gráfics descriptius variables qualitatives
- Grandària Mostral
 - Càlcul de la grandaria mostral
 - Càlcul del poder
 - Generació de nombres aleatoris
- Exercici Pràctic

Estadística Descriptiva

3

Variables cuantitativas

	Paramètricos	No paramètricos
Localización	Media	Moda, Mediana
Dispersión	Varianza Desviación tipica	Rango (min/max) Intervalo Interquartílico (P ₂₅ – P ₇₅)
Asimetría	Asimètria	
Gràficos	Media (Intervalo de confianza)	Diagrama de cajas, Diagrama de puntos, Histograma

• Descripción de variables cuantitativas

summarize variables

by vargrupo, sort: summarize variables

summarize edads	sero				
Variable	Obs	Mean	Std. Dev.	Min	Max
edadsero		26.50658	5.866372	13.94795	50.27869
by sex, sort:s	ummarize edac	lsero			
-> sex = male Variable		Mean	Std. Dev.	Min	Max
		26.89573	6.025914	13.94795	50.27869
-> sex = female	e e				
Variable	Obs	Mean	Std. Dev.	Min	Max
edadsero	94	25.05758	4.997224	16.68969	38.8356

Variables cuantitativas

• Descripción de variables cuantitativas mean variables, over(vargrupo)

• Descripción de variables cuantitativas ameans variables, add(#)

Variable interval]	Туре	0bs	Mean	[95% Conf.	
edadsero	Arithmetic	444	26.50658	25.95942	7.05374
	Geometric	444	25.90548	25.39713	26.424
	Harmonic	444	25.33755	24.85023	5.84438

7

Variables cuantitativas

• Calculo de estadísticos de variable en función de otra tabstat variables, by(vargrupo) statistics(lista)

tabstat	edadsero, h	oy(sex) sta	tistics(c	count mean	median min	max semean)
_	for variabl					
sex	N	mean	p50	min	max	se(mean)
male	+ 327	26.66295	25.67671	13.94795	50.27869	.3273748
female	88	25.03693	24.51507	16.68969	38.83562	.5338185
Total	+ 415	26.31815	25.44763	13.94795	50.27869	.2833073

- Calculo de intervalos de confianza
 - ci variables, normal (poisson) (binomial)
 - cii denominador numerador, poisson
 - cii denominador numerador , binomial
 - cii n media desviacion , normal

. ci edadsero				
Variable	Obs	Mean	Std. Err.	[95% Conf. Interval]
edadsero	415	26.31815	.2833073	25.76125 26.87505
. cii 1000 4, Variable	poisson Exposure	Mean	Std. Err.	Poisson Exact [95% Conf. Interval]
. cii 100 10,		.004	.002	.0010899 .0102416
Variable	Obs	Mean	Std. Err.	Binomial Exact [95% Conf. Interval]
	100	.1	.03	.0490047 .176222

Variables cuantitativas

• Calculo de percentiles

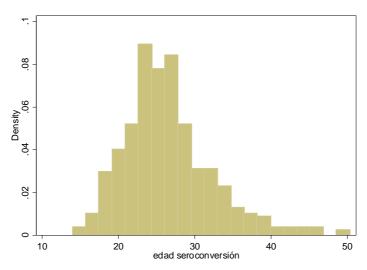
centile variables, c(5 10 25 50 75 90 95)

centile edads	sero, c(5	10 25 50 75 9	90 95)		
Variable	Obs	Percentile	Centile	Binom. I [95% Conf.	-
edadsero	415	5	18.28884	17.70245	18.96871
į		10	19.87397	18.96774	20.64329
į		25	22.60274	21.81362	23.32044
į		50	25.44763	24.96491	26.14509
į		75	28.95628	28.25659	29.87559
į		90	34.17821	32.42179	35.35978
İ		95	37.12159	35.35755	39.54065

• Histograma

histogram variable, bin(#) width(#) normal
kdensity by(vargrup)

histogram edadsero,



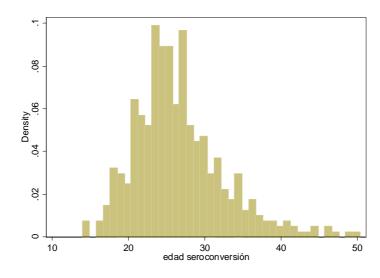
11

Variables cuantitativas

• Histograma

histogram variable, bin(#) width(#) normal
kdensity by(vargrup)

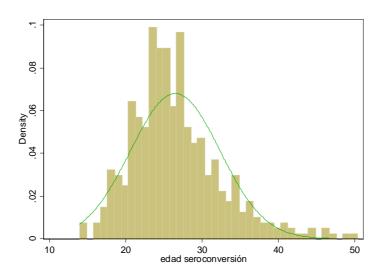
histogram edadsero, bin(40)



• Histograma

histogram variable, bin(#) width(#) normal
kdensity by(vargrup)

histogram edadsero, bin(40)normal



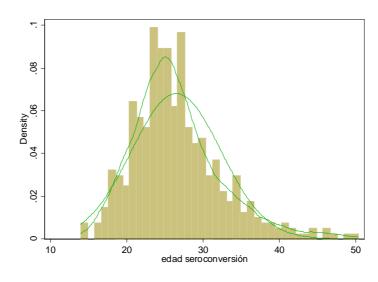
13

Variables cuantitativas

• Histograma

histogram variable, bin(#) width(#) normal
kdensity by(vargrup)

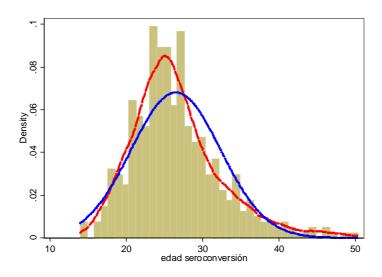
histogram edadsero, bin(40)normal kdensity



• Histograma

histogram variable, bin(#) width(#) normal kdensity by(vargrup)

```
histogram edadsero, bin(40)normal kdensity
kdenopts(lpattern("_") lcolor(red) lwidth(thick))
normopts(lpattern(".-") lcolor(blue) lwidth(thick))
```



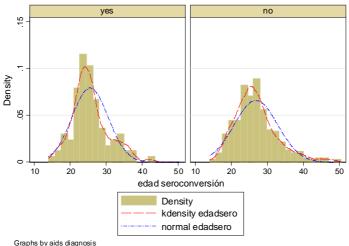
15

Variables cuantitativas

Histograma

histogram variable, bin(#) width(#) normal kdensity by(vargrup)

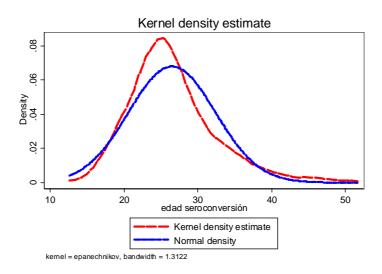
histogram edadsero, normal normopts(lpattern(".-") lcolor(blue)) kdensity kdenopts(lpattern(" ") lcolor(red)) by(aids)



· Gràfico densidad

kdensity variable, normal

kdensity edadsero, lpattern("_") lcolor(red) lwidth(thick))
normal normopts(lpattern(".-") lcolor(blue) lwidth(thick))



17

Variables cuantitativas

• Diagrama de cajas graph box variable, over(vargrup)

graph box datasero, over(sex)

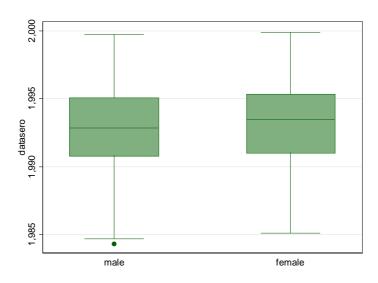
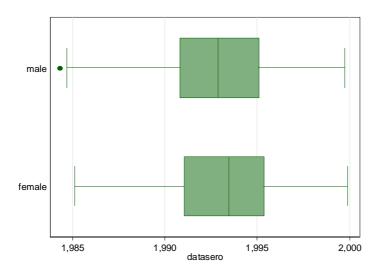


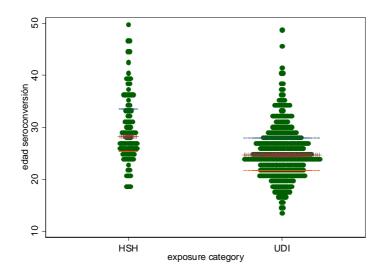
Diagrama de cajas
 graph hbox variable, over(vargrup)
 graph hbox datasero, over(sex)



19

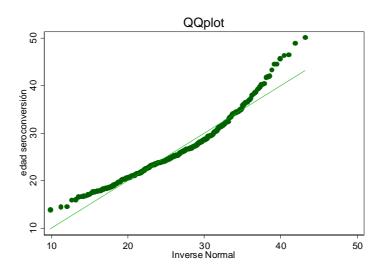
Variables cuantitativas

Diagrama de puntos
 dotplot var, over(vargrup) center median bar
 dotplot edadsero , over(expcateg) center median bar



• QQplot (valor obs vs valor esperado percentil en la normal) quorm var, opciones gràfico

qnorm edadsero , title(QQplot)

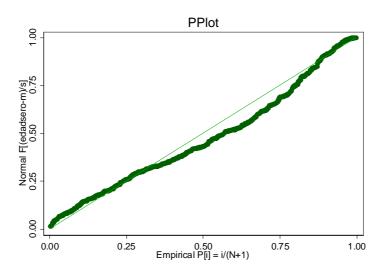


21

Variables cuantitativas

• PPplot (percentil obs vs percentil esperado en la normal) pnorm var, opciones gràfico

pnorm edadsero , title(PPplot)



	Medidas	Gràficos
Univariante	Tablas de Frecuencia	Pastel, Gràfico barras
Bivariante	Tablas de contingencia	Gràfico de barras , Gràfico de barras acumulado
Estudio cohorte	Tasa de incidencia Incidencia acumulada Riesgo Relativ	
Estudio de casos-control	Odds Odds ratio	

Variables cualitativas

• Calculo de tablas de frecuencia tabl variables, plot tabulate variable

. tab1 sex ex			
sexe	Freq.	Percent	Cum.
female	329 88	21.10	100.00
	417		
-> tabulation	of expcateg		
exposure category	Freq.	Percent	
homo idu	83 334	19.90	19.90
Total	417	100.00	

• Tablas de contingencia

tabulate variable1 variable2 ,row col chi exact

. tabulate e	expcateg aids,	row col	chi exact	
Key				
frequency row percentage				
exposure	aids diag	gnosis		
category	yes	no	Total	
homo	20	 63	83	
į	24.10	75.90	100.00	
į	21.28	19.50	19.90	
idu	74	260	334	
j	22.16	77.84	100.00	
ļ	78.72	80.50	80.10	
+ Total	94	323	417	
j	22.54	77.46	100.00	
ĺ	100.00	100.00	100.00	
Pe	earson chi2(1)	0.143	34 Pr = 0.	.705
F	isher's exact	; =	0.	769
1-sided F	isher's exact	; =	0.	402

25

Variables cualitativas

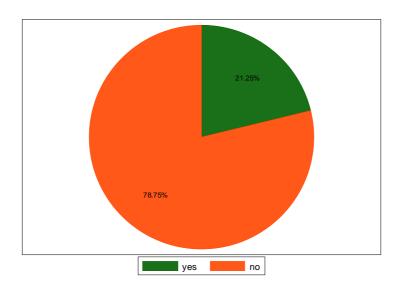
• Tablas de contingencia

table var1 var2 var3, row col c(estad var)

exposure		and aid: le					
category	yes		yes				
homo	20			71			
Total	 77	252	17	71			
. table ex	pcateg	aids se	k, row (col c(mean	edadsero)		
	 		se	exe and aid	ds diagnosis		
exposure	 	ı	se male	exe and aid		- female -	
exposure category	 + 29.46	i yes 	nale no 	exe and aid Total	ds diagnosis	- female - no 	Total

• Diagrama de sectores

```
graph pie ,over(var1) plabel(_all percent)
graph pie ,over(aids) plabel(_all percent)
```

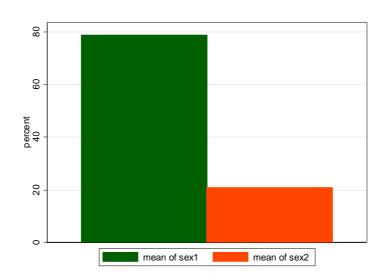


27

Variables cualitativas

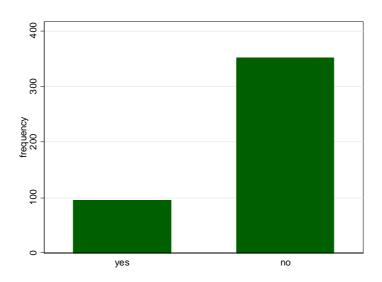
• Diagrama de barras

```
graph bar (stat) vars ,over(vargrupo)
  tabulate sex, generate (sex)
  graph bar sex1 sex2, percent
```



• Catplot

catplot {bar|hbar} catvar1 , by(var2)
 {percent|percent(var2)} asyvars stack
catplot bar aids

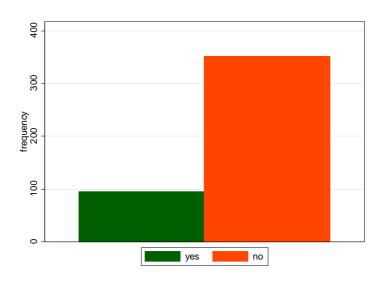


29

Variables cualitativas

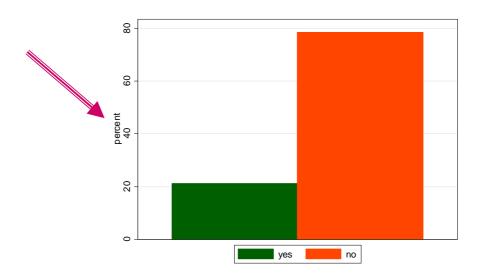
• Catplot

catplot {bar|hbar} catvar1 , by(var2)
 {percent|percent(var2)} asyvars stack
catplot bar aids, asyvars



• Catplot

catplot {bar|hbar} catvar1 , by(var2)
 {percent|percent(var2)} asyvars stack
catplot bar aids, asyvars percent

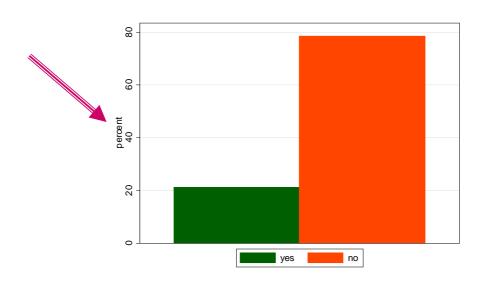


31

Variables cualitativas

• Catplot

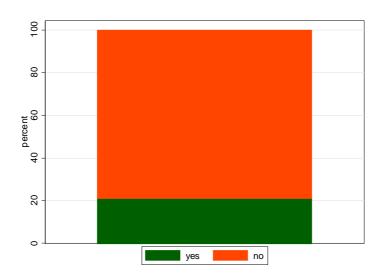
catplot {bar|hbar} catvar1 , by(var2)
 {percent|percent(var2)} asyvars stack
catplot bar aids, asyvars percent



• Catplot

catplot {bar|hbar} catvar1 , by(var2)
{percent|percent(var2)} asyvars stack

catplot bar aids, asyvars percent stack



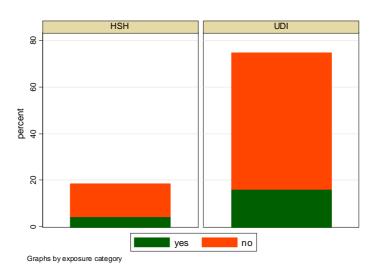
33

Variables cualitativas

Catplot

catplot {bar|hbar} catvar1 , by(var2)
{percent|percent(var2)} asyvars stack

catplot bar aids, asyvars percent stack by(expcateg)

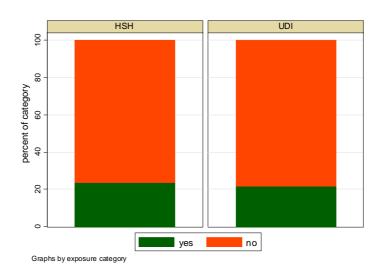


34

• Catplot

catplot {bar|hbar} catvar1 , by(var2) {percent|percent(var2)} asyvars stack

catplot bar aids, asyvars percent(expcateg) stack by(expcateg)



35

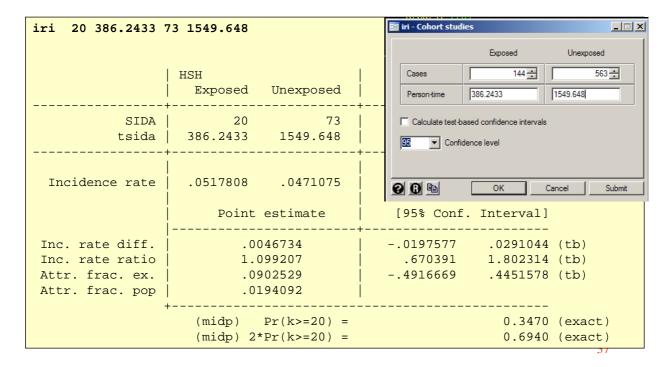
Tablas epidemiológicas
Estudio de cohortes.Calculo de tasas de incidencia ir varcaso varexp vartemprisk,options

ir aids HSH tsida				
	HSH Exposed Unexposed	 Total		
	20 73 386.2433 1549.648	93 1935.892		
Incidence rate		.0480399		
	Point estimate	[95% Conf.	Interval]	
Inc. rate diff. Inc. rate ratio Attr. frac. ex. Attr. frac. pop	.0046734 1.099207 .0902529 .0194092	0197577 .670391 4916669	1.802314	(tb)
	(midp) Pr(k>=20) = (midp) 2*Pr(k>=20) =			(exact) (exact)

Tablas epidemiológicas

• Estudio de cohortes. Calculo de tasas de incidencia

iri casos_a temps_a casos_b temps_b,tb



Tablas epidemiológicas

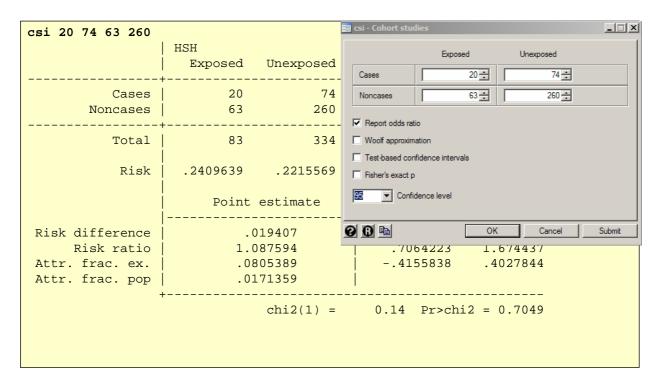
• Estudio de cohortes. Calculo de incidencia acumulada cs varcaso varexp, options

	HSH Exposed	Unexposed	 Total	
Cases Noncases	+	74 260	+ 94 323	
Total	+ 83	334	+ 417	
Risk	 .2409639	.2215569	.2254197	
	 Point	estimate	 [95% Conf.	Interval]
Risk difference Risk ratio Attr. frac. ex. Attr. frac. pop	1.0	19407 87594 05389 71359	0828121 .7064223 4155838	1.674437
-	+	chi2(1) =	0.14 Pr>chi	2 = 0.7049

Tablas epidemiológicas

• Calculo de incidencia acumulada

csi casos_a casos_b nocasos_c nocasos_d



Tablas epidemiológicas

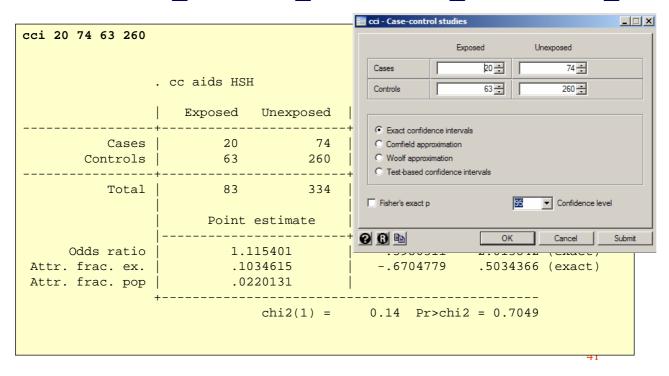
• Estudio de casos-controles.Calculo de incidencia acumulada cc varcaso varexp, options

cs aids HSH									
. cc aids HSH									
	Exposed	Unexposed	Total	Proportion Exposed					
Cases Controls	20 63	74 260	94 323	0.2128 0.1950					
Total	83	334	+ 417	0.1990					
	 Point	estimate	 [95% Conf.						
Odds ratio Attr. frac. ex. Attr. frac. pop	.10	15401 34615 20131	.5986311 2.013842 6704779 .5034366						
chi2(1) = 0.14 Pr>chi2 = 0.7049									

Tablas epidemiológicas

• Calculo de incidencia acumulada

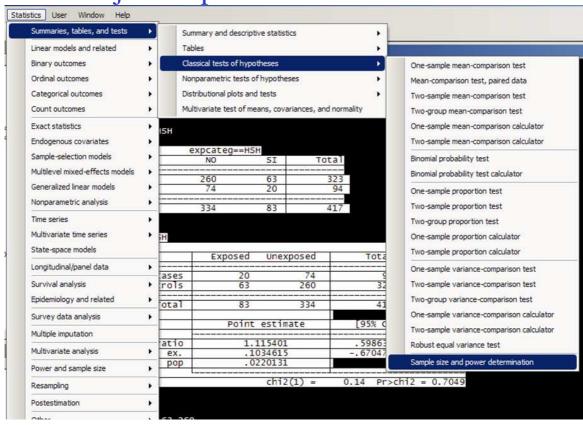
cci casos_a casos_b nocasos_c nocasos_d



Cálculo de Tamaño muestral

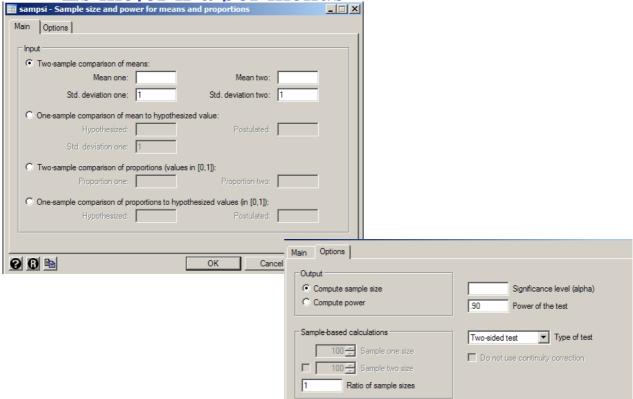
Cálculo tamaño muestral

• Es mejor ir a por menús



Cálculo tamaño muestral

• Es mejor ir a por menús



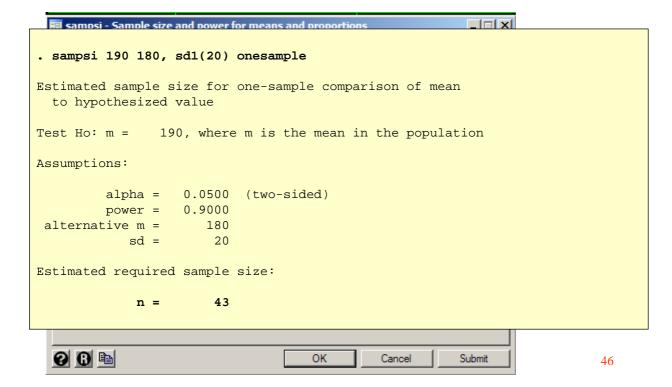
Ejemplos calculo muestral

• Diferencia de medias

```
sampsi - Sample size and power for means and proportion
sampsi 180 190, sd1(20) sd2(25)
Estimated sample size for two-sample comparison of means
Test Ho: m1 = m2, where m1 is the mean in population 1
                    and m2 is the mean in population 2
Assumptions:
         alpha =
                   0.0500 (two-sided)
         power =
                   0.9000
            m1 =
                      180
                     190
            m2 =
           sd1 =
                       20
           sd2 =
                    1.00
         n2/n1 =
Estimated required sample sizes:
            n1 =
                      108
            n2 =
                      108
 8 8
                                               Cancel
                                                          Submit
```

Ejemplos calculo muestral

• Diferencia de media frente a un valor estándar



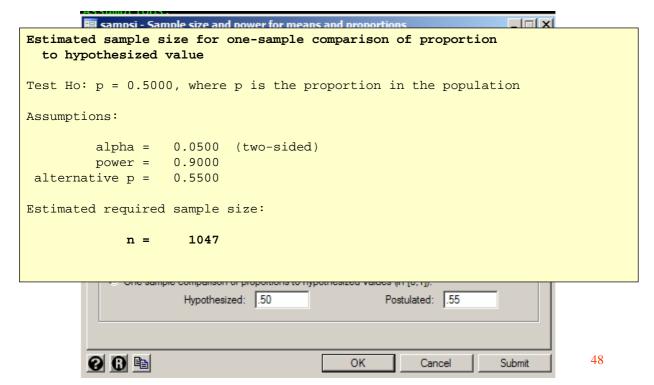
Ejemplos calculo muestral

• Diferencia de proporciones

```
sampsi - Sample size and power for means and prop
. sampsi .10 .15
Estimated sample size for two-sample comparison of proportions
Test Ho: p1 = p2, where p1 is the proportion in population 1
                    and p2 is the proportion in population 2
Assumptions:
         alpha =
                   0.0500 (two-sided)
         power =
                  0.9000
                  0.1000
            p1 =
            p2 = 0.1500
         n2/n1 = 1.00
Estimated required sample sizes:
            n1 =
                      957
            n2 =
                      957
  0 0 🗎
                                                                            47
                                               Cancel
                                                         Submit
```

Ejemplos calculo muestral

• Diferencia de una proporción frente a un estàndar



Generación de valores aleatorios

• Crea secuencias de números aleatorios a partir de una semilla que es fija al abrir Stata pero se puede cambiar

set seed 339487731

• Crea una variable U que tiene una secuencia de números aleatorios entre [0,1)

generate u = runiform()

• Crea una variable Z a partir de una variable normal con media 0 y desviación típica 1

generate z = rnormal()

 Crea una variable N a partir de una variable normal con media m y desviación típica s

generate n = rnormal(m,s)

• Crea una variable B a partir de una variable binomial con n observaciones y un probabilidad p de éxito

generate b = rbinomial(n,p)

• Crea una variable P a partir de una variable Poisson con un número de casos promedio de m

generate r = rpoisson(m)

49

Generación secuencia numeros aleatorios

Se utiliza el comando ralloc

ralloc bloc size treat, nsubj(387) osize(3) eq ntreat(2)
 sav(mywide)

· / · · – ·	,						
	StratID	b1oc	size	SeqInB1k	treat	Secuencia	
1	1	X	2	1	В		
2	1	1	B	2	A	de	
3	1	2	4	1	В	Tratamiento	
4	1	2	4	2	A	Tratamiento	
5	1	2	4	3	A		
6	1	2	4	4	В	Orden	
7	1	3	4	1	A		
8	1	3	4	2	В	dentro del	
9	1	3	4	3	A	bloque	
10	1	3	4	4	В	oroque	
11	1	4	4	1	A		
12	1	4	4	2	A	Número de	
13	1	4	4	3	B		
14	1	4	4	4	В	bloque	
15	1	5	6	1	В		
16	1	5	6	2	A		
17	1	5	6	3	A	Tomoño del	
18	1	5	6	4	A	Tamaño del	
19	1	5	6	5	В	bloque	
20	1	5	6	6	В	010400	
21	1	6	2	1	В		
22	1	6	2	2	A	50	